期末專題技術報告：Small-C 互動式解譯器

林煜博

Spring 2026

Contents

1 摘要 **3**

2 系統架構設計說明 **4**
2.1 模組劃分 4
2.2 資料流程 6
2.3 類別結構 6

3 各模組設計決策與實作細節 **9**
3.1 lexer.py —詞法分析器 9
3.1.1 前處理：`preprocess()` 9
3.1.2 詞法掃描：`Lexer.tokenize()` 9
3.2 parser.py —語法分析器與 AST 9
3.2.1 AST 節點設計 9
3.2.2 遞迴下降語法分析 9
3.2.3 函式定義與變數宣告的歧義消解 10
3.3 interpreter.py —樹狀走訪直譯器 10
3.3.1 兩種執行模式 10
3.3.2 控制流程以 Python 例外實作 10
3.3.3 整數截斷 10
3.4 memory.py —記憶體模型 11
3.5 symtable.py —符號表 11
3.6 builtins_funcs.py —內建函式 11
3.7 repl.py —互動式介面 11
3.7.1 多行輸入收集：`ReplInputCollector` 11
3.7.2 else 跨行偵測 12
3.7.3 環境指令 12

4 符號表的資料結構設計 **13**
4.1 概觀 13
4.2 Symbol 類別 13
4.3 作用域堆疊 13
4.4 變數宣告流程 14
4.5 數值讀寫的型別感知 14

5 記憶體模型的模擬方式 **15**

5.1 設計概觀 15
5.2 Bump Allocator（線性堆疊配置器） 15
5.3 NULL 指標保留 15
5.4 資料型別的模擬 15
5.5 int32() 的設計 15
5.6 C 字串的模擬 16

6 測試策略與測試結果分析 **17**
6.1 測試集設計策略 17
6.2 測試結果 17

7 開發過程中遭遇的主要困難及其解決方案 **18**

8 工作分配與貢獻說明 **19**

9 附錄：**Small-C** 語言支援範圍摘要 **20**
9.1 支援的語言特性 20
9.2 不支援的特性 20

1 摘要

本專題實作一個 Small-C 語言的互動式解譯器（Interactive Interpreter），以純 Python 3 撰寫，不依賴任何第三方套件。解譯器採用經典的四階段管線架構：前處理（Preprocessor）→ 詞法分析（Lexer）→ 語法分析（Parser）→ 樹狀走訪直譯（Tree-Walking Interpreter），並提供完整的 REPL（Read-Eval-Print Loop）操作介面，支援程式的互動輸入、載入、編輯、執行與除錯追蹤。

本報告詳細說明各模組的設計決策與實作細節、符號表與記憶體模型的資料結構設計、測試策略與結果分析，以及開發過程中遭遇的技術困難與解決方案。

2 系統架構設計說明

2.1 模組劃分

整個解譯器共分為七個 Python 模組，各司其職：

- **`main.py`**：程式進入點，建立並啟動 `REPL` 物件。
- **`lexer.py`**：詞法分析層。`preprocess()` 負責展開無參數 `#define` 巨集；`Lexer.tokenize()` 逐字元掃描，將原始碼轉為 `Token` 串流供 Parser 消費。
- **`parser.py`**：語法分析層，包含兩大部分：上半部定義所有 AST 節點類別（`Expr`、`Stmt` 及其子類別），下半部實作遞迴下降 Parser，將 Token 串流轉為抽象語法樹（AST）。
- **`interpreter.py`**：直譯執行層。走訪 Parser 產生的 AST，以 Python 例外實作 `break` ／ `continue` ／ `return` 控制流程，支援完整程式執行（`execute`）與互動片段執行（`execute_interactive`）兩種模式。
- **`memory.py`**：記憶體模型。以固定大小的整數陣列模擬線性記憶體空間，提供 bump allocator 進行配置與釋放；模組層級的 `int32()` 函式負責 32 位元整數截斷，供其他模組共用。
- **`symtable.py`**：符號表。以作用域堆疊（`list[dict]`）管理變數名稱與記憶體位址的對映，實現 C 語言的區域／全域作用域與變數遮蔽行為。
- **`builtins_funcs.py`**：內建函式庫。以分派字典實作全部 22 個內建函式，包含輸出入（`printf`、`scanf`）、字串處理（`strlen`、`strcpy` 等）、數學運算（`abs`、`sqrt` 等）及工具函式（`atoi`、`itoa` 等）。
- **`repl.py`**：互動介面。`ReplInputCollector` 追蹤大括號深度與字串狀態，收集跨行輸入；`REPL` 以分派字典處理 16 個環境指令，並處理互動模式下的 `else` 跨行銜接問題。

圖一為各模組的相依關係圖：

由圖中可見各模組的依賴關係如下：

- `repl.py` 是整合核心，依賴 `interpreter.py` 執行程式。
- `interpreter.py` 依賴 `parser.py`（取得 AST）、`memory.py`（記憶體讀寫）、`symtable.py`（符號查詢）與 `builtins_funcs.py`（內建函式）。
- `parser.py` 依賴 `lexer.py` 取得 Token 串流。
- `memory.py` 被 `symtable.py` 與 `builtins_funcs.py` 共用，是底層的共享資源。

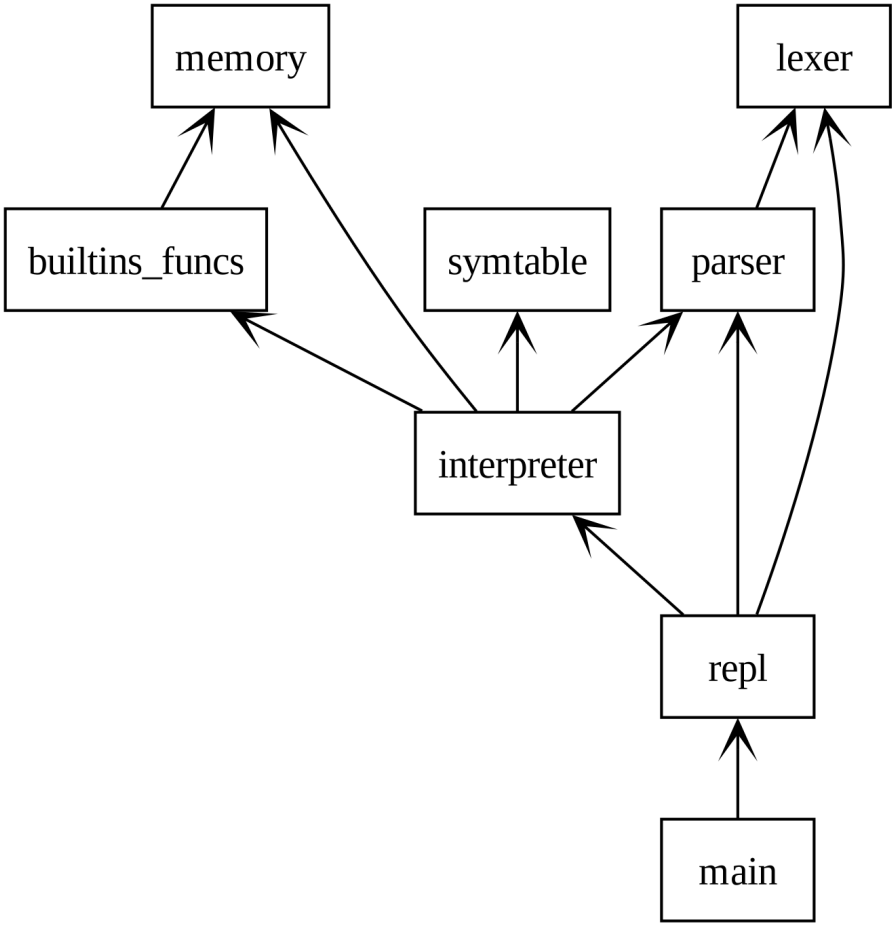

圖 1: 圖一：模組相依關係圖

2.2 資料流程

原始碼從輸入到輸出，嚴格單向流動：

```
使用者輸入（REPL）或 LOAD 指令
        │
        ▼
  preprocess()          ── #define 巨集展開
        │
        ▼
  Lexer.tokenize()      ── 字元掃描 → Token 串流
        │
        ▼
  Parser.parse()        ── 遞迴下降 → AST
        │
        ▼
  Interpreter.execute() ── 走訪 AST → 產生輸出
        │
        ▼
   stdout 輸出
```

互動模式（直接在提示符下輸入語句）走 `execute_interactive()` 路徑，跳過「必須有 `main()`」的限制；`RUN` 指令走 `execute()` 路徑，要求程式含有 `main()` 函式作為進入點。

2.3 類別結構

圖二與圖三為各模組中主要類別與 AST 節點的完整類別圖：

AST 節點分為三個層次：

- 頂層節點
  - `Program`：整份程式的根節點，包含所有頂層宣告
  - `FuncDef`：函式定義，含名稱、回傳型別、參數列表與函式本體
- **`Expr`**（運算式）子類別
  - 算術／邏輯：`BinOp`（二元運算）、`UnaryOp`（一元運算）
  - 賦值：`Assignment`（含複合賦值 `+=` 等）
  - 呼叫：`Call`（函式呼叫）
  - 基本值：`Identifier`（識別字）、`Number`（整數）、`Char`（字元）、`StringLiteral`（字串）
  - 指標：`AddressOf`（取址 `&`）、`Deref`（解參考 `*`）、`ArrayAccess`（陣列索引）
- **`Stmt`**（陳述式）子類別
  - 區塊：`Block`（大括號區塊）

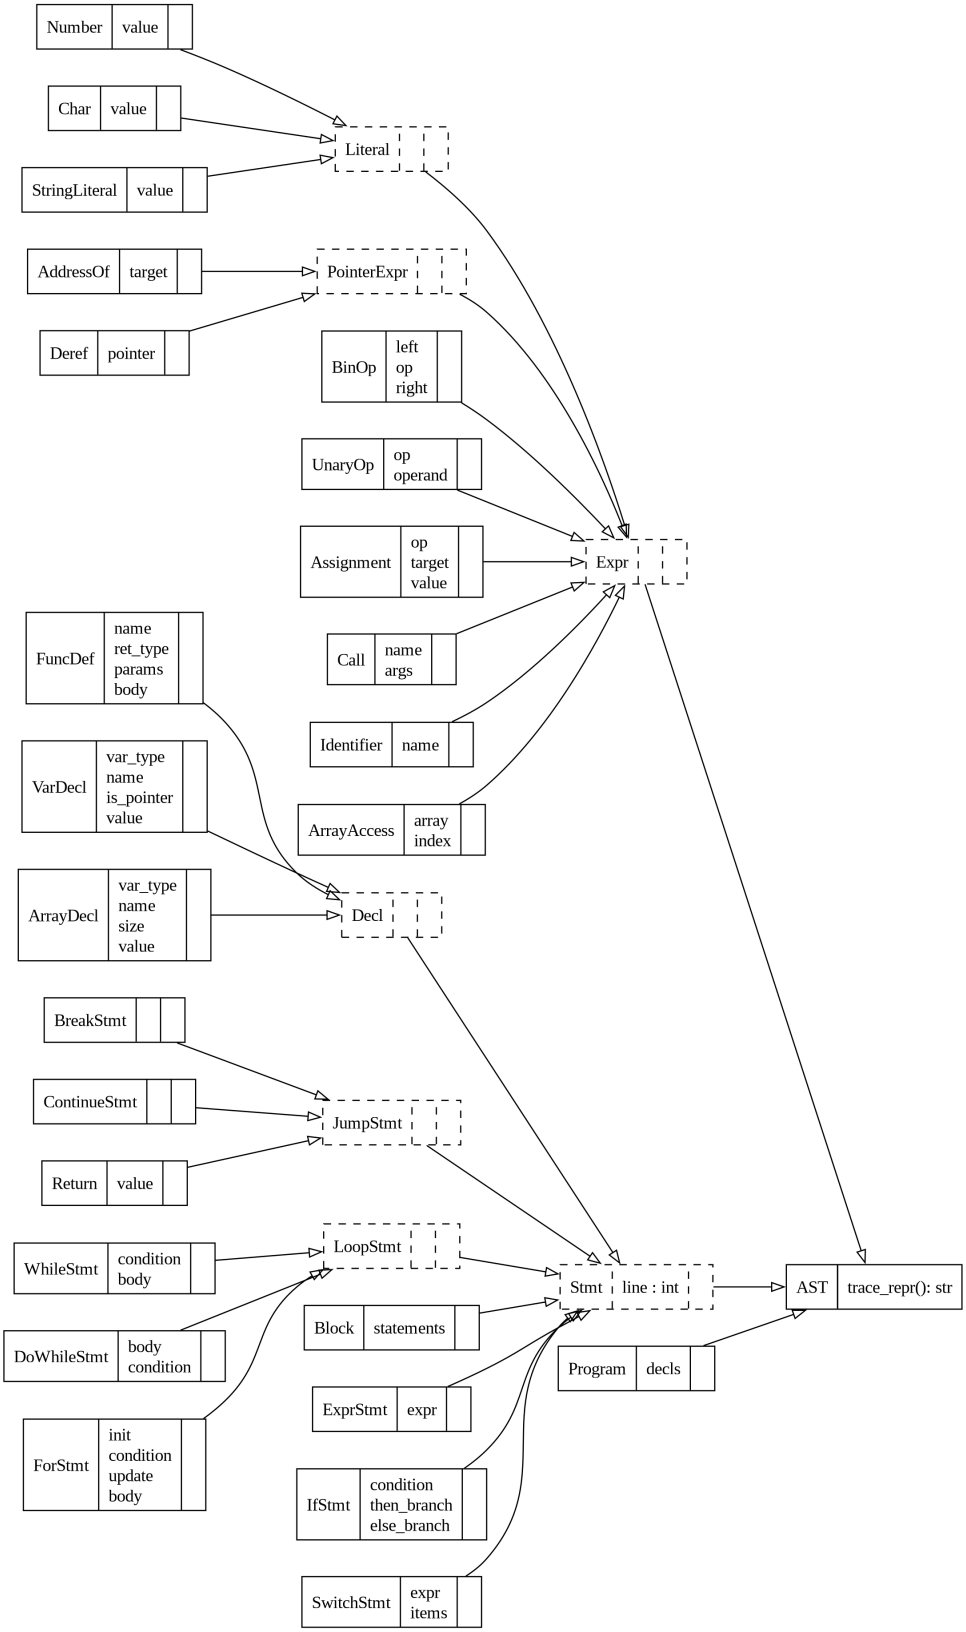

圖 2: 圖二：AST 節點繼承層次

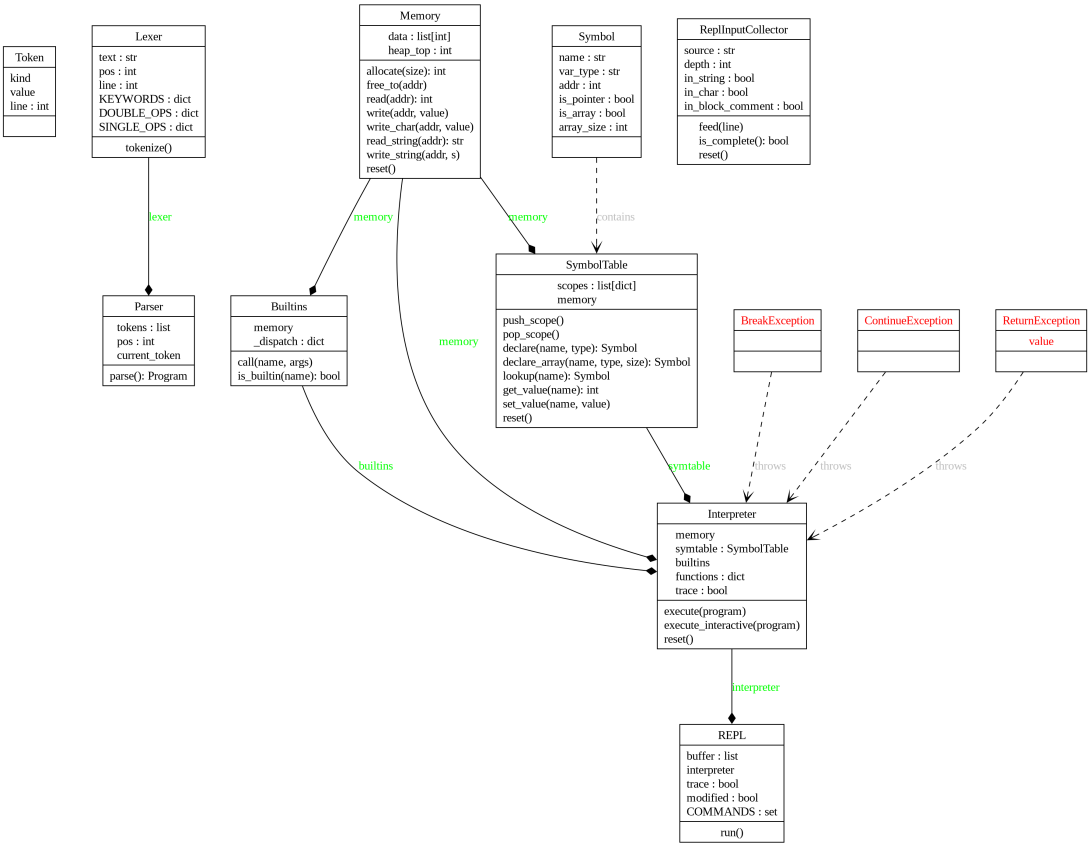

圖 3: 圖三：執行期模組類別圖

- 選擇：`IfStmt`（if/else）、`SwitchStmt`（switch/case）
- 迴圈：`WhileStmt`、`DoWhileStmt`、`ForStmt`
- 跳躍：`BreakStmt`、`ContinueStmt`、`Return`
- 宣告：`VarDecl`（變數宣告）、`ArrayDecl`（陣列宣告）
- 其他：`ExprStmt`（運算式陳述式）

3 各模組設計決策與實作細節

3.1 lexer.py —詞法分析器

3.1.1 前處理：preprocess()

在詞法分析之前，先以 preprocess() 處理 #define 巨集。設計決策：

- 識別字邊界感知替換：不用簡單的字串取代（避免把 MAX_SIZE 中的 MAX 誤換），而是以手工分詞方式逐字元掃描，僅在完整識別字邊界上進行替換。
- 字串與字元字面量豁免：掃描時追蹤是否處於雙引號（字串）或單引號（字元）內部，若在其中則不進行替換，避免污染字串內容。
- 行號補償：#define 行被移除後，後續行號會偏移。透過在移除的位置插入空行保持行號一致，確保錯誤訊息中的行號對應原始輸入。

3.1.2 詞法掃描：Lexer.tokenize()

採用手工撰寫的字元掃描器（character scanner）：

掃描器的兩個關鍵設計：雙字元運算子（==、!=、<=、<< 等）優先於單字元匹配，避免歧義；每個 Token 攜帶行號供錯誤回報使用。產生的 Token 類型如下：

Token 類型	範例	說明
關鍵字	int、if、while、return	語言保留字
IDENT	foo、x、arr	識別字（變數／函式名稱）
NUMBER	42、-7、0xFF	整數常數，支援十六進位
CHAR	'A'、'\n'、'\0'	字元常數，支援跳脫序列
STRING	"hello\n"	字串字面量
運算子	+、==、&&、<<	算術、邏輯、位元運算子
分隔符	;、{、}	陳述式與區塊邊界

3.2 parser.py —語法分析器與 AST

3.2.1 AST 節點設計

所有 AST 節點繼承自 AST 基底類別，並各自實作 trace_repr() 方法，用於 TRACE 模式顯示人可讀的描述字串（如 while (i < 10)、x = 5），而非 Python repr()。

3.2.2 遞迴下降語法分析

Parser 類別以遞迴下降法（Recursive Descent Parsing）實作，表達式優先順序由低到高共 13 層：

`assignment → logic_or → logic_and → bit_or → bit_xor → bit_and`
`→ equality → relational → shift → additive → multiplicative`
`→ unary → primary`
每一層對應一個私有方法（如 `_assignment()`、`_logic_or()` …），僅在必要時呼叫下一層，自然表達優先順序。

3.2.3 函式定義與變數宣告的歧義消解

語法上，`int foo(...)` 與 `int foo;` 的開頭相同，無法僅憑一個 Token 區分。`is_func_def()` 方法進行 3–4 個 Token 的前瞻（lookahead）：

1. 確認第一個 Token 是型別關鍵字。
2. 確認第二個 Token 是識別字（函式或變數名稱）。
3. 確認第三個 Token（跳過可能的 `*`）是 `(`，以此判斷為函式定義。

3.3 interpreter.py —樹狀走訪直譯器

3.3.1 兩種執行模式

- **`execute(program)`**：用於 `RUN` 指令，要求程式頂層含有 `main()` 函式。先掃描頂層節點，收集所有函式定義存入 `self.funcs` 字典、執行全域變數宣告，最後呼叫 `main()`。
- **`execute_interactive(program)`**：用於 REPL 互動輸入，直接執行片段程式碼，不要求 `main()`，函式定義會累積在 `self.funcs` 中跨行保留。

3.3.2 控制流程以 Python 例外實作

`break`、`continue`、`return` 不以旗標或全域狀態傳遞，而是以 Python 例外機制實作：

Small-C 語句	拋出例外	捕捉位置
`break`	`BreakException`	`while` / `for` / `do-while` 的執行迴圈
`continue`	`ContinueException`	同上
`return expr`	`ReturnException(value)`	`_eval_call()` 函式呼叫點

此設計的優點是程式碼簡潔——不需要在每個遞迴呼叫中傳遞「是否需要中斷」的狀態，結構清晰地反映了 C 語言控制流程的語意。

3.3.3 整數截斷

所有整數運算結果在寫入記憶體前，統一透過 `int32()` 截斷為 32 位元有號整數，模擬 C 語言的整數溢位行為。`int32()` 定義在 `memory.py` 作為模組層級函式，由 `interpreter.py` 與 `builtins_funcs.py` 直接 import 使用，避免散落的行內遮罩（如 `& 0xFFFFFFFF`）。

3.4 memory.py —記憶體模型

詳見第四章「記憶體模型的模擬方式」。

3.5 symtable.py —符號表

詳見第三章「符號表的資料結構設計」。

3.6 builtins_funcs.py —內建函式

`Builtins` 類別以一個 `_dispatch` 字典將函式名稱映射到對應的私有方法，供 `Interpreter._eval_call()` 查詢：

```
self._dispatch = {
    'printf':  self._printf,
    'scanf':   self._scanf,
    'strlen':  self._strlen,
    'sqrt':    self._sqrt,
    ...
}
```

設計決策：

- 統一參數型別：所有內建函式接收已求值的整數引數；字串引數以記憶體位址傳遞，由內建函式內部呼叫 `memory.read_string(addr)` 轉為 Python 字串。
- **`printf`** 格式碼：手工解析格式字串，支援 `%d`、`%c`、`%s`、`%x`、`%%`，不支援欄位寬度等進階格式，符合作業規格。
- **`scanf`**：以 Python `input()` 讀取整行，再依格式碼解析，將結果寫入指標所指位址。
- 錯誤處理：`sqrt()` 負數引數、`mod()` 除零均拋出 `RuntimeError`，訊息格式符合評分規格。

3.7 repl.py —互動式介面

3.7.1 多行輸入收集：`ReplInputCollector`

為了支援跨行輸入函式定義（如 `APPEND` 模式），`ReplInputCollector` 維護三個狀態：

狀態欄位	作用	影響
`depth`（大括號深度）	追蹤 `{` / `}` 巢狀層次	歸零時視為輸入完整
`in_string`	是否處於雙引號字串內	為真時 `{` / `}` 不計入深度
`in_char`	是否處於單引號字元內	同上，避免誤計

3.7.2 else 跨行偵測

互動模式下，使用者可能分行輸入：

```
sc> if (x > 0) {
>     printf("pos\n");
> } else {
```

REPL 在 `{` 深度歸零後不立即執行，而是記錄為 `pending_source`，在下一行輸入後先檢查是否以 `else` 開頭，若是則繼續收集。

3.7.3 環境指令

REPL 支援 16 個大小寫不敏感的環境指令，以 `dispatch` 字典分派：

類別	指令	功能
程式管理	`LOAD`、`SAVE`、`NEW`	載入檔案、儲存緩衝區、清空狀態
緩衝區編輯	`LIST`、`EDIT`、`DELETE`、`INSERT`、`APPEND`	檢視與修改緩衝區內容
執行與檢查	`RUN`、`CHECK`	執行程式、僅做語法檢查
除錯	`TRACE`、`VARS`、`FUNCS`	追蹤模式、顯示變數、顯示函式清單
系統	`ABOUT`、`HELP`、`QUIT/EXIT`	版本資訊、說明、離開

4 符號表的資料結構設計

4.1 概觀

符號表（`symtable.py`）負責管理 Small-C 程式執行期間所有變數的名稱、型別與記憶體位址的對應關係。它刻意與記憶體讀寫分離：符號表只管「名稱 → 位址」的對映，實際的數值讀寫一律委派給 `Memory` 模組。

4.2 Symbol 類別

`Symbol` 是符號表的基本單元，儲存一個變數的完整後設資料：

欄位	型別	說明
`name`	`str`	變數名稱
`var_type`	`str`	型別（`'int'`、`'char'`、`'void'`）
`addr`	`int`	在 `Memory` 中的起始位址
`is_pointer`	`bool`	是否為指標型別（宣告帶 `*`）
`is_array`	`bool`	是否為陣列型別（宣告帶 `[]`）
`array_size`	`int`	陣列元素數量；非陣列時為 0

4.3 作用域堆疊

`SymbolTable` 以 `list[dict]` 實作作用域堆疊：

```
scopes = [
   { 'x': Symbol, 'arr': Symbol, ... },  ← scopes[0]：全域作用域（永久存在）
    { 'a': Symbol, 'temp': Symbol, ... },  ← scopes[1]：第一層函式呼叫
    { 'i': Symbol, ... },                  ← scopes[2]：巢狀函式呼叫
]
```

- **`push_scope()`**：函式呼叫時新增一層空字典。
- **`pop_scope()`**：函式返回時移除最內層；全域作用域（`scopes[0]`）永遠不被移除。
- **`lookup(name)`**：從 `scopes[-1]` 往 `scopes[0]` 逐層搜尋，自動實現 C 語言的變數遮蔽（shadowing）行為。

4.4 變數宣告流程

```
declare('x', 'int')
    │
    ├─ 確認同作用域無同名變數
    ├─ memory.allocate(1)  → 取得位址 addr
    ├─ memory.write(addr, 0)  → 初始化為 0
    └─ 建立 Symbol，存入 scopes[-1]
```

陣列宣告（`declare_array`）則一次配置連續的 `size` 個記憶體單元，所有位置初始化為 0。

4.5 數值讀寫的型別感知

`set_value()` 在寫入時依型別選擇截斷方式：

- `char`（非指標）：呼叫 `memory.write_char()`，截斷為 8 位元有號整數（-128 ～127）。
- 其他型別（含指標）：呼叫 `memory.write()`，截斷為 32 位元有號整數。

此設計確保 `char` 型別的語意正確，不需要在直譯器的每個賦值處另行判斷。

5 記憶體模型的模擬方式

5.1 設計概觀

`Memory` 類別以一個固定大小的 Python `list[int]`（預設 65,536 個單元）模擬 Small-C 的記憶體空間。每個列表元素代表一個記憶體單元，可儲存 `int` 或 `char` 的數值。

5.2 Bump Allocator（線性堆疊配置器）

記憶體管理採用最簡單且高效的 bump allocator：

```
記憶體空間：
  [0]  [1][2]...[N]  [N+1]...[M]  [M+1]...
   ↑                   ↑
  NULL                heap_top（下次配置起點）
（保留，不使用）
```

- **`allocate(size)`**：從 `heap_top` 開始配置 `size` 個連續單元，回傳起始位址，並將 `heap_top` 往後移動 `size`。時間複雜度 O(1)。
- **`free_to(addr)`**：將 `heap_top` 回退到指定位址，一次性釋放其上方的所有空間。在函式返回時，直譯器記錄呼叫前的 `heap_top`，返回後呼叫 `free_to()` 批次釋放區域變數，無需逐一追蹤。

5.3 NULL 指標保留

位址 0 被保留作為 NULL 指標，`heap_top` 從 1 開始。所有指標解參考操作若位址為 0，直譯器拋出 `Runtime error: null pointer dereference`。

5.4 資料型別的模擬

Small-C 型別	記憶體單元數	寫入方式	有效範圍
`int`	1	`write()` + `int32()`	−2,147,483,648 ～2,147,483,647
`char`	1	`write_char()`	−128 ～127
`int*` / `char*`	1	`write()`	整數位址值
`int[N]`	N	各元素獨立 `write()`	同 `int`

5.5 int32() 的設計

```python
def int32(value: int) -> int:
    value = int(value)
    return ((value + 2**31) % 2**32) - 2**31
```

此函式利用模運算將任意整數截斷到 32 位元有號整數範圍，正確處理 Python 大整數的溢位行為，避免使用位元遮罩（`& 0xFFFFFFFF`）後再補號的繁瑣寫法。作為模組層級函式，可直接被 `interpreter.py` 和 `builtins_funcs.py` import 使用。

5.6 C 字串的模擬

字串以 C 風格的 null 終止序列（null-terminated string）儲存：

```
"hello"  →  ['h','e','l','l','o','\0']
            addr  addr+1 addr+2 ...   addr+5
```

- **`write_string(addr, s)`**：將 Python 字串逐字元寫入記憶體，並在末尾附加 `\0`（值為 0）。
- **`read_string(addr)`**：從位址開始讀取，直到遇到值為 0 的單元，回傳 Python 字串。字元值以 `chr(ch & 0xFF)` 轉換，正確處理負值 char。

6 測試策略與測試結果分析

6.1 測試集設計策略

測試集位於 `tests/` 目錄，共 10 個 `.sc` 測試程式，每個配有對應的 `.expected` 預期輸出檔。`.expected` 由輔助腳本 `tests/gen_expected.py` 從解譯器實際執行結果自動產生，確保預期輸出與解譯器行為一致。

測試涵蓋五大類別，共 10 個測試程式：

測試程式	類別	驗證重點
`test_01_arithmetic.sc`	基本算術	算術、位元、複合賦值運算子；整數除法取整（10/3=3）
`test_02_variables.sc`	基本算術	`int`/`char` 宣告、十六進位字面值、`abs`/`max`/`sqrt` 等內建函式
`test_03_control_if.sc`	控制結構	`if`/`else if`/`else` 鏈式分支、`&&` 邏輯運算子
`test_04_control_loop.sc`	控制結構	`while`/`for`/`do-while` 三種迴圈、`break`、`continue`
`test_05_functions.sc`	函式與遞迴	帶回傳值函式、`void` 函式、call by value、多層呼叫
`test_06_recursion.sc`	函式與遞迴	遞迴階乘、費氏數列、次方；遞迴基本情況（base case）
`test_07_array.sc`	陣列與指標	陣列宣告、索引存取、線性搜尋、透過指標傳入函式
`test_08_pointer.sc`	陣列與指標	取址 `&`、解參考 `*`、指標賦值、指標偏移、bubble sort
`test_09_error_runtime.sc`	錯誤處理	執行期除以零錯誤；驗證訊息格式與程式即時中止
`test_10_error_syntax.sc`	錯誤處理	語法錯誤偵測（缺少 `;`）；驗證行號回報格式

6.2 測試結果

所有 10 個測試均通過，實際輸出與 `.expected` 完全一致。部分代表性結果：

測試	重點驗證	結果
`test_01`	10 » 1 = 5，a %= 4 = 0	通過
`test_03`	`else if` 三向分支	通過
`test_06`	factorial(7) = 5040，F(14) = 377	通過
`test_08`	`*p = 99` 正確改變原變數	通過
`test_09`	除以零後程式中止，不輸出後續行	通過

7 開發過程中遭遇的主要困難及其解決方案

開發過程中遭遇的五個主要問題整理如下：

困難	問題根源	解決方案
`#define` 展開誤入字串	使用 `str.replace()` 不感知字串邊界，導致字串內的子字串也被替換	改為逐字元掃描，追蹤 `in_string`/`in_char` 狀態，加識別字邊界檢查
`#define` 行刪除造成行號偏移	直接刪除 `#define` 行使後續行號少 1	改為將 `#define` 行替換為空行，保持行數不變
互動模式 `else` 跨行誤判	大括號歸零後立即送出，`else` 進入下一輪解析造成語法錯誤	歸零後先存入 `pending_source`，下一行若以 `else` 開頭則合併繼續收集
多次 `RUN` 狀態殘留	每次執行未重置 `Memory` 與 `SymbolTable`，全域變數與 `heap_top` 持續累積	`RUN` 前呼叫 `interpreter.reset()`，清零記憶體並重建空的全域作用域
`Block` 記憶體洩漏	大括號區塊結束後區域變數未釋放，`heap_top` 只增不減	進入 `Block` 前記錄 `save_top`，`finally` 區塊中呼叫 `free_to(save_top)`

8 工作分配與貢獻說明

本專題為個人獨立完成。以下為各階段的工作內容說明：

開發階段	內容	對應模組
詞法分析	Token 定義、字元掃描器、`#define` 前處理	`lexer.py`
語法分析	所有 AST 節點類別設計、遞迴下降 Parser	`parser.py`
記憶體模型	`Memory`、`int32()`、bump allocator	`memory.py`
符號表	`Symbol`、`SymbolTable`、作用域堆疊	`symtable.py`
直譯器核心	`Interpreter`、控制流程例外、兩種執行模式	`interpreter.py`
內建函式	全部 22 個內建函式（I/O、字串、數學、工具）	`builtins_funcs.py`
REPL	指令分派、多行收集、`else` 跨行偵測	`repl.py`
測試	10 個測試程式與預期輸出	`tests/`
報告	本技術報告	`docs/report.md`

9 附錄：Small-C 語言支援範圍摘要

9.1 支援的語言特性

類別	支援內容
資料型別	`int`（32 位元有號）、`char`（8 位元有號）、`int*`、`char*`（指標）
字面值	十進位整數、十六進位（`0x`/`0X`）、字元（含 `\n`/`\t`/`\0` 等跳脫序列）、字串
變數	全域與區域變數宣告（含初始化）、一維陣列
運算子	算術、位元、邏輯、比較、前置 `++`/`--`、複合賦值（`+=`/`-=`/`*=`/`/=`/`%=`）、取址 `&`、解參考 `*`
控制結構	`if`/`else` `if`/`else`、`while`、`do-while`、`for`、`break`、`continue`、`return`、`switch`/`case`（bonus）
函式	定義、呼叫、遞迴、call by value、指標參數
前處理	無參數 `#define` 巨集展開
內建函式	22 個（I/O、字串處理、數學運算、記憶體與工具）

9.2 不支援的特性

類別	不支援項目
資料型別	`float`、`double`、`long`、`short`、`unsigned`
型別系統	`struct`、`union`、`enum`、`typedef`、多層指標（`int**`）
陣列	多維陣列
運算子	後置 `++`/`--`
前處理器	函式式巨集、`#include`
函式	前向宣告